

Прогнозирование намерений. Исследование свойств локальных моделей при пространственном декодировании сигналов головного мозга.*

Шиянов В. А., Болоболова Н. А., Самохина А. М., Мокруполо М. Н.

nataboll@mail.ru

В данной работе исследуются механизмы регуляции движения конечностей нейронами головного мозга. Проверяется гипотеза о влиянии перемещения зон активности нейронов на траекторию движения конечности. Высокая размерность признакового пространства сигналов приводит к неустойчивости модели машинного обучения. Сигнал высокой размерности предлагается аппроксимировать локальной моделью, что существенно уменьшает размерность пространства параметров. Пространство параметров локальной модели используется как признаковое пространство. Таким образом, результирующая модель становится проще и устойчивее. В задаче используются данные электрокортикограмм, собранные на основе исследований активности нейронов головного мозга обезьян.

Ключевые слова: *Brain-Computer Interface (BCI), feature engineering.*

nataboll@mail.ru

1 Введение

Нейрокомпьютерный интерфейс (Brain Computer Interface) [11] позволяет восстановить мобильность людей с нарушениями двигательных функций. Алгоритм BCI транслирует сигналы нейронов головного мозга в команды для исполняющей системы [11]. Это дает возможность регулировать движение роботизированной конечности в соответствии с механизмами нервной регуляции. [5].

*Работа выполнена при финансовой поддержке РФФИ, проект №00-00-00000. Научный руководитель: Стрижов В. В. Задачу поставил: Стрижов В. В. Консультант: Исаченко Р. О.

В последнее время большое количество работ посвящено методам считывания мозговой активности и декодирования информации [9] [16] [10] [7] [8] [3] [11]. В этой работе используются данные сигналов, полученных инвазивным методом электрокортикографии (ECoG) [15]. Сложность декодирования заключается в избыточной размерности сигнала. Модель прогнозирования намерений является неустойчивой. Также к нестабильности модели приводит наличие сторонних шумов, накладывающихся на сигналы в естественной среде: импульсов других долей головного мозга и сигналов из внешней среды. Для построения системы нейрокомпьютерного интерфейса необходимо использовать простую и устойчивую модель.

Исследование состоит в восстановлении зависимостей между сигналами ECoG и движениями конечностей. Для точного предсказания траектории движения в трехмерном пространстве требуется снизить размерность признакового пространства и снизить влияние шумов на предсказания.

Стандартные подходы состоят в извлечении информативных признаков из пространственных, частотных и временных характеристик сигнала [11] [1]. Большинство методов в смежных работах исследуют частотные характеристики [4], [6], [10]. В работах [7] [12] рассматриваются все признаки вне зависимости от их природы. Наиболее распространёнными моделями являются алгоритмы PLS [14] [7], PCA [2], [16]. В работах [17] используются алгоритмы, построенные на скрытых марковских моделях. В работах [10] [16] авторы рассматривают различные участки сигнала как слова. В работе [12] исследован метод отбора признаков с помощью квадратичного программирования (Quadratic Programming Feature Selection [13]). Результаты работ недостаточно устойчивы по отношению к шумовым сигналам из-за больших вариаций амплитуд [6], [16], несмотря на рассмотренные в этих работах механизмы пространственной фильтрации сигналов.

В данной работе для моделирования фронта распределения сигнала предлагается использовать локальную модель. Движение фронта возбуждения приближается с помощью локальной модели прогнозирования движений. В качестве признакового описания объектов используются параметры построенной локальной модели. Полученный метод значи-

51 тельно снижает размерность данных, использует пространственную информацию и сохра-
 52 няет свойства распространения сигнала. Как следствие, количество параметров конечной
 53 модели значительно уменьшается. Получается более простая аппроксимация сигнала вы-
 54 сокой размерности и более устойчивая прогностическая модель.

55 В эксперименте используются данные с сайта neurotycho.org. Сбор данных произво-
 56 дился с использованием методики Multi-Dimensional Recording. Запись сигналов ECoG и
 57 траектории движения руки проводилась одновременно. Каждый из экспериментов длился
 58 15 минут, первые 8 минут производилась запись обучающей выборки, оставшиеся 7 минут
 59 - запись тестовой выборки.

60

61

62 2 Постановка задачи

63 Исходные данные - отрезки многомерных временных рядов электрокортикограммы.
 64 Пространство исходных данных имеет размерность $T \times N \times F$, где N - число каналов, T
 65 - количество отсчетов времени, F - дискретный спектр наблюдаемых частот. Используем
 66 двумерное представление данных: построим матрицу значений напряжения $\mathbf{X} \in \mathbb{R}^{T \times (N \circ F)}$.
 67 Пусть $\mathbf{Y} \in \mathbb{R}^{T \times 3}$ - массив ответов. Необходимо построить информативное признаковое
 68 пространство для предсказания траектории движения конечности.

69 Исходные данные представлены в виде массивов:

$$70 \quad \mathbf{X} = \{x_{ti}\}_{\substack{t=1,\dots,T, \\ i=1,\dots,N \circ F}}; \quad (1)$$

$$71 \quad \mathbf{Y} = \{y_{ti}\}_{\substack{t=1,\dots,T, \\ i=1,2,3}}; \quad (2)$$

73 где \mathbf{Y} - массив ответов. Объектом будем называть вектор $\mathbf{x}_t \in \mathbb{R}^{N \circ F}$ с измерениями в
 74 каждый отрезок времени, $i = 1, \dots, T$. Вектор состоит из $N \circ F$ элементов, каждый из
 75 которых соответствует каналу и частоте. Значение y_{ti} отвечает i -й координате траектории
 76 движения конечности.

77 Модель прогнозирования $f : \mathbf{X} \rightarrow \mathbf{Y}$ предлагается искать классе суперпозиции двух мо-

78 делей: $f = g \circ h : \mathbf{X} \rightarrow \mathbf{Y}$. Локальная модель $g : \mathbf{X} \times \Theta \rightarrow \mathbf{X}$ использует локальную
 79 пространственную структуру сигнала для аппроксимации перемещения фронта возбуж-
 80 дения. Примером локальной модели является модель авторегрессии:

$$81 \quad \begin{pmatrix} x_{t+1,i} & x_{t,i} & \cdots & x_{t-d,i} \\ x_{t,i} & x_{t-1,i} & \cdots & x_{t-d-1,i} \\ \cdots & \cdots & \cdots & \cdots \\ x_{T,i} & \cdots & \cdots & \cdots \end{pmatrix} \begin{pmatrix} \theta_1^i \\ \theta_2^i \\ \cdots \\ \theta_d^i \end{pmatrix}. \quad (3)$$

82 Модель $g(\mathbf{X}, \Theta)$ решает задачу оптимизации параметров Θ^{ji} для одного временного ряда
 83 \mathbf{x}_i :

$$84 \quad \Theta^i(\mathbf{X}) = \arg \min_{\Theta^i} g(\mathbf{x}_i, \Theta^i) \quad (4)$$

85 Параметры модели $g(\mathbf{X}, \Theta^i)$, $i = 1, \dots, T$, используются как новое признаковое простран-
 86 ство $\Theta \in \mathbb{R}^{T \times d}$. Примером модели $h(\Theta, \mathbf{w}) : \Theta \rightarrow \mathbf{Y}$ является модель линейной регрессии с
 87 параметрами \mathbf{w} . На этапе применения модели $h(\Theta, \mathbf{w})$ построенное признаковое описание
 88 Θ используется для предсказания траекторий $\hat{\mathbf{Y}}$. Параметры \mathbf{w} модели $h(\Theta, \mathbf{w})$ находятся
 89 путем минимизации функции потерь $L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h)$:

$$90 \quad \mathbf{w}^* = \arg \min_{\mathbf{w}} L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h). \quad (5)$$

91 В качестве функции потерь можно выбрать, например, квадратичную ошибку:

$$92 \quad L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h) = \|\mathbf{Y} - \hat{\mathbf{Y}}\|_2^2. \quad (6)$$

93 Общая постановка задачи:

$$94 \quad \mathbf{w}, \Theta = \arg \min_{\mathbf{w}, \Theta} L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h). \quad (7)$$

95 Цель работы состоит в нахождении оптимальной локальной модели $g(\mathbf{X}, \Theta)$ для построе-
 96 ния информативного признакового пространства.

97 3 Выбор локальной модели

98 Активность нейронов представляет собой временные вспышки сигналов различной ин-
 99 тенсивности, их суперпозицию и распространение. Каждый канал имеет доступ к сигналам
 100 некоторого количества нейронов, находящихся в небольшой области пространства. Каж-
 101 дый нейрон соединен с помощью множества отростков с приблизительно 20 тысячами
 102 других нейронов. Таким образом, нейроны и связи между ними образуют граф, описы-
 103 вающий возможные пути распространения сигналов. Точно учесть локальную структуру
 104 графа при описании сигнала невозможно, так как это потребует большого количества
 105 вычислительных ресурсов. В связи с этим предлагается модель локальной аппроксима-
 106 ции формы и перемещения фронта. На изображениях [которые сейчас у Алины и будут
 107 тут позже, если все это не окажется бессмысленным бредом] можно заметить, что фронт
 108 перемещается по сети в большинстве случаев как единое целое, при этом интенсивность
 109 сигнала максимальна в центре множества активных узлов и убывает к периферии. У такой
 110 структуры сигнала есть возможное объяснение, основанное на устройстве нейронной сети.
 111 Нейрон имеет большое количество небольших отростков - дендритов, основной функци-
 112 ей которых является передача возбуждения к телу нейрона извне, и обычно один аксон,
 113 служащий для передачи импульса от тела другим нейронам или мышечной ткани. Полу-
 114 чается, что импульсы собираются от периферии к центру каждого нейрона, после чего
 115 суммарный импульс, если он достаточно велик, передается по аксону дальше. С помо-
 116 щью первого предположения можно объяснить распределение интенсивности в пределах
 117 группы нейронов, а с помощью второго - направленное перемещение пика интенсивности.
 118 Эти утверждения можно применить не только к одному нейрону, но и к небольшой сово-
 119 купности нейронов, если считать интенсивностью сигнала такой совокупности суммарную
 120 интенсивность. В связи с этим выдвигаются гипотезы:

121 4 Гипотеза нормального распределения

122 Интенсивность сигнала подчиняется модели нормального распределения: $\mathbf{x}_t \in$
 123 $\mathcal{N}(\mathbf{m}(t), \Sigma(t))$. Математическое ожидание $\mathbf{m}(t)$ аппроксимирует положение пика интен-
 124 сивности в момент времени t , а ковариационная матрица $\Sigma(t)$ описывает форму фронта.

125 5 Гипотеза гамма-распределения

126 Если предположить дополнительно, что на распределение интенсивности в пределах
 127 группы нейронов влияет направленное распространение сигнала внутри группы, можно
 128 выдвинуть гипотезу $x_{ti} \in \Gamma(k, \Theta)$, $i = 1, \dots, N$, так как гамма-распределение не является
 129 симметричным.

130 Литература

- 131 [1] David M. Alexander, Peter Jurica, Chris Trengove, Andrey R. Nikolaev, Sergei Gepshtein, Mikhail
 132 Zvyagintsev, Klaus Mathiak, Andreas Schulze-Bonhage, Johanna Ruescher, Tonio Ball, and Cees
 133 van Leeuwen. Traveling waves and trial averaging: The nature of single-trial and averaged brain
 134 responses in large-scale cortical signals. *NeuroImage*, 73:95–112, jun 2013.
- 135 [2] Hai bin Zhao, Chun yang Yu, Chong Liu, and Hong Wang. ECoG-based brain-computer
 136 interface using relative wavelet energy and probabilistic neural network. In *2010 3rd International
 137 Conference on Biomedical Engineering and Informatics*. IEEE, oct 2010.
- 138 [3] David T Bundy, Mrinal Pahwa, Nicholas Szrama, and Eric C Leuthardt. Decoding three-
 139 dimensional reaching movements using electrocorticographic signals in humans. *Journal of Neural
 140 Engineering*, 13(2):026021, feb 2016.
- 141 [4] César Márquez Chin, Milos R Popovic, Adam Thrasher, Tracy Cameron, Andres Lozano, and
 142 Robert Chen. Identification of arm movements using correlation of electrocorticographic spectral
 143 components and kinematic recordings. *Journal of Neural Engineering*, 4(2):146–158, apr 2007.
- 144 [5] John P. Donoghue. Bridging the brain to the world: A perspective on neural interface systems.
 145 *Neuron*, 60(3):511–521, nov 2008.
- 146 [6] Andrey Eliseyev and Tatiana Aksenova. Stable and artifact-resistant decoding of 3d hand
 147 trajectories from ECoG signals using the generalized additive model. *Journal of Neural
 148 Engineering*, 11(6):066005, oct 2014.
- 149 [7] Andrey Eliseyev and Tetiana Aksenova. Penalized multi-way partial least squares for smooth
 150 trajectory decoding from electrocorticographic (ECoG) recording. *PLOS ONE*, 11(5):e0154878,
 151 may 2016.

-
- [8] Anna Gaglianese, Ben M. Harvey, Mariska J. Vansteensel, Serge O. Dumoulin, Nick F. Ramsey, and Natalia Petridou. Separate spatial and temporal frequency tuning to visual motion in human MT+ measured with ECoG. *Human Brain Mapping*, 38(1):293–307, sep 2016.
- [9] Kejia Hu, Mohsen Jamali, Ziev B. Moses, Carlos A. Ortega, Gabriel N. Friedman, Wendong Xu, and Ziv M. Williams. Decoding unconstrained arm movements in primates using high-density electrocorticography signals for brain-machine interface use. *Scientific Reports*, 8(1), jul 2018.
- [10] Carlos A. Loza and Jose C. Principe. Unsupervised robust detection of behavioral correlates in ECoG. In *2017 8th International IEEE/EMBS Conference on Neural Engineering (NER)*. IEEE, may 2017.
- [11] Soichiro Morishita, Keita Sato, Hidenori Watanabe, Yukio Nishimura, Tadashi Isa, Ryu Kato, Tatsuhiro Nakamura, and Hiroshi Yokoi. Brain-machine interface to control a prosthetic arm with monkey ECoGs during periodic movements. *Frontiers in Neuroscience*, 8, dec 2014.
- [12] Anastasia Motrenko and Vadim Strijov. Multi-way feature selection for ECoG-based brain-computer interface. *Expert Systems with Applications*, 114:402–413, dec 2018.
- [13] I Rodriguez-Lujan, R Huerta, C Elkan, and C Santa Cruz. Quadratic programming feature selection. *Journal of Machine Learning Research*, 2010.
- [14] Roman Rosipal and Nicole Krämer. Overview and recent advances in partial least squares. In *Subspace, Latent Structure and Feature Selection*, pages 34–51. Springer Berlin Heidelberg, 2006.
- [15] J.I. Sirven. Electrocorticogram (ECOG). In *Encyclopedia of the Neurological Sciences*, pages 1080–1083. Elsevier, 2014.
- [16] Yilin Song, Yao Wang, and Jonathan Viveni. Unsupervised learning of spike patterns for seizure detection and wavefront estimation of high resolution micro electrocorticographic (μ ECoG) data. *IEEE Transactions on NanoBioscience*, 16(6):418–427, sep 2017.
- [17] Rui Zhao, Gerwin Schalk, and Qiang Ji. Coupled hidden markov model for electrocorticographic signal classification. In *2014 22nd International Conference on Pattern Recognition*. IEEE, aug 2014.