

Прогнозирование намерений. Исследование свойств локальных моделей при пространственном декодировании сигналов головного мозга.*

Шиянов В. А., Болоболова Н. А., Самохина А. М., Мокруполо М. Н.

nataboll@mail.ru

В данной работе исследуются механизмы регуляции движения конечностей нейронами головного мозга. Проверяется гипотеза о влиянии перемещения зон активности нейронов на траекторию движения конечности. Высокая размерность признакового пространства сигналов приводит к неустойчивости модели машинного обучения. Сигнал высокой размерности предлагается аппроксимировать локальной моделью, что существенно уменьшает размерность пространства параметров. Пространство параметров локальной модели используется как признаковое пространство. Таким образом, результирующая модель становится проще и устойчивее. В задаче используются данные электрокортикограмм, собранные на основе исследований активности нейронов головного мозга обезьян.

Ключевые слова: *Brain-Computer Interface (BCI), feature engineering.*

nataboll@mail.ru

1 Введение

Нейрокомпьютерный интерфейс (Brain Computer Interface) [11] позволяет восстановить мобильность людей с нарушениями двигательных функций. Алгоритм BCI транслирует сигналы нейронов головного мозга в команды для исполняющей системы [11]. Это дает возможность регулировать движение роботизированной конечности в соответствии с механизмами нервной регуляции. [5].

*Работа выполнена при финансовой поддержке РФФИ, проект №00-00-00000. Научный руководитель: Стрижов В. В. Задачу поставил: Стрижов В. В. Консультант: Исаченко Р. О.

В последнее время большое количество работ посвящено методам считывания мозговой активности и декодирования информации [9] [16] [10] [7] [8] [3] [11]. В этой работе используются данные сигналов, полученных инвазивным методом электрокортикографии (ECoG) [15]. Сложность декодирования заключается в избыточной размерности сигнала. Модель прогнозирования намерений является неустойчивой. Также к нестабильности модели приводит наличие сторонних шумов, накладывающихся на сигналы в естественной среде: импульсов других долей головного мозга и сигналов из внешней среды. Для построения системы нейрокомпьютерного интерфейса необходимо использовать простую и устойчивую модель.

Исследование состоит в восстановлении зависимостей между сигналами ECoG и движениями конечностей. Для точного предсказания траектории движения в трехмерном пространстве требуется снизить размерность признакового пространства и снизить влияние шумов на предсказания.

Стандартные подходы состоят в извлечении информативных признаков из пространственных, частотных и временных характеристик сигнала [11] [1]. Большинство методов в смежных работах исследуют частотные характеристики [4], [6], [10]. В работах [7] [12] рассматриваются все признаки вне зависимости от их природы. Наиболее распространёнными моделями являются алгоритмы PLS [14] [7], PCA [2], [16]. В работах [17] используются алгоритмы, построенные на скрытых марковских моделях. В работах [10] [16] авторы рассматривают различные участки сигнала как слова. В работе [12] исследован метод отбора признаков с помощью квадратичного программирования (Quadratic Programming Feature Selection [13]). Результаты работ недостаточно устойчивы по отношению к шумовым сигналам из-за больших вариаций амплитуд [6], [16], несмотря на рассмотренные в этих работах механизмы пространственной фильтрации сигналов.

В данной работе для моделирования фронта распределения сигнала предлагается использовать локальную модель. Движение фронта возбуждения приближается с помощью локальной модели прогнозирования движений. В качестве признакового описания объектов используются параметры построенной локальной модели. Полученный метод значи-

51 тельно снижает размерность данных, использует пространственную информацию и сохра-
 52 няет свойства распространения сигнала. Как следствие, количество параметров конечной
 53 модели значительно уменьшается. Получается более простая аппроксимация сигнала вы-
 54 сокой размерности и более устойчивая прогностическая модель.

55 В эксперименте используются данные с сайта neurotycho.org. Сбор данных произво-
 56 дился с использованием методики Multi-Dimensional Recording. Запись сигналов ECoG и
 57 траектории движения руки проводилась одновременно. Каждый из экспериментов длился
 58 15 минут, первые 8 минут производилась запись обучающей выборки, оставшиеся 7 минут
 59 - запись тестовой выборки.

60

61

62 2 Постановка задачи

63 Исходные данные - отрезки многомерных временных рядов электрокортикограммы.
 64 Пусть $\mathbf{X} \in \mathbb{R}^{T \times N \times F}$ – массив значений напряжения, где N – число каналов, T – время, F –
 65 дискретный спектр наблюдаемых частот. Необходимо построить информативное призна-
 66 ковое пространство для предсказания траектории движения конечности.
 67 Исходные данные представлены в виде массивов:

$$68 \quad \mathbf{X} = \{x_{tji}\}_{t=1,\dots,T; \ j=1,\dots,N; \ i=1,\dots,F}; \quad (1)$$

69

$$70 \quad \mathbf{Y} = \{y_{tji}\}_{t=1,\dots,T; \ j=1,2,3; \ i=1,\dots,F}; \quad (2)$$

71 где \mathbf{X} - набор сигналов, \mathbf{Y} - массив ответов. Объектом будем называть матрицу \mathbf{x}_t с из-
 72 мерениями в каждый отрезок времени, $i = 1, \dots, T$. Матрица состоит из N строк, каждая
 73 из которых соответствует каналу. Элемент x_{tji} строки x_{tj} содержит значение напряжения
 74 на i -й частоте. Значение y_{tji} отвечает j -й координате траектории движения конечности на
 75 i -й частоте, соответствующей объекту \mathbf{x}_t .

76 Модель прогнозирования $f : \mathbf{X} \rightarrow \hat{\mathbf{Y}}$ предлагается искать классе суперпозиции двух мо-
 77 делей: $f(\mathbf{X}) = h(g(\mathbf{X}, \Theta), \mathbf{w})$. Здесь $\hat{\mathbf{Y}}$ - предсказания модели f для обучающей выборки

78 **X**. Локальная модель $g : \mathbf{X} \times \Theta \rightarrow \mathbf{X}$. использует локальную пространственную структу-
 79 ру сигнала для аппроксимации перемещения фронта возбуждения. Примером локальной
 80 модели является модель авторегрессии:

$$81 \begin{pmatrix} x_{t+1,j,i} & x_{t,j,i} & \cdots & x_{t-d,j,i} \\ x_{t,j,i} & x_{t-1,j,i} & \cdots & x_{t-d-1,j,i} \\ \cdots & \cdots & \cdots & \cdots \\ x_{T_{ji},j,i} & \cdots & \cdots & \cdots \end{pmatrix} \begin{pmatrix} \theta_1^{ji} \\ \theta_2^{ji} \\ \cdots \\ \theta_d^{ji} \end{pmatrix}. \quad (3)$$

82 В данной постановке модель $g(\mathbf{X}, \Theta)$ решает задачу оптимизации параметров Θ^{ji} для од-
 83 ного временного ряда \mathbf{x}_{ji} . Будем рассматривать модель $G : \mathbf{X} \times \Theta \rightarrow \mathbf{X}$, выход которой Θ
 84 строится как совокупность выходов $g : \{\Theta^{ji}\}_{ji}$. Параметры модели $G(\mathbf{X}, \Theta)$ используются
 85 как новое признаковое пространство $\Theta \in \mathbb{R}^{T \times d}$. Примером модели $h(\mathbf{w}, \Theta) : \Theta \rightarrow \hat{\mathbf{Y}}$ явля-
 86 ется модель линейной регрессии с параметрами \mathbf{w} . На этапе применения модели $h(\mathbf{w}, \Theta)$
 87 построенное признаковое описание Θ используется для предсказания траекторий $\hat{\mathbf{Y}}$. Пара-
 88 метры \mathbf{w} модели $h(\mathbf{w}, \Theta)$ находятся путем минимизации функции потерь $L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h)$:

$$89 \mathbf{w}^* = \arg \min_{\mathbf{w}} L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h). \quad (4)$$

90 В качестве функции потерь можно выбрать, например, квадратичную ошибку:

$$91 L(\mathbf{Y}, \hat{\mathbf{Y}}) = \|\mathbf{Y}_j - \hat{\mathbf{Y}}_j\|_2^2. \quad (5)$$

92 Цель работы состоит в нахождении оптимальной локальной модели $g(\Theta, \mathbf{X})$ для построе-
 93 ния информативного признакового пространства.

94 3 Выбор локальной модели

95 Активность нейронов представляет собой временные вспышки сигналов различной ин-
 96 тенсивности, их суперпозицию и распространение. Каждый канал имеет доступ к сигналам
 97 некоторого количества нейронов, находящихся в небольшой области пространства. Каж-

98 дый нейрон соединен с помощью множества отростков с приблизительно 20 тысячами
 99 других нейронов. Таким образом, нейроны и связи между ними образуют граф, описы-
 100 вающий возможные пути распространения сигналов. Точно учесть локальную структуру
 101 графа при описании сигнала невозможно, так как это потребует большого количества
 102 вычислительных ресурсов. В связи с этим предлагается модель локальной аппроксима-
 103 ции формы и перемещения фронта. На изображениях [которые сейчас у Алины и будут
 104 тут позже, если все это не окажется бессмысленным бредом] можно заметить, что фронт
 105 перемещается по сети в большинстве случаев как единое целое, при этом интенсивность
 106 сигнала максимальна в центре множества активных узлов и убывает к периферии. У такой
 107 структуры сигнала есть возможное объяснение, основанное на устройстве нейронной сети.
 108 Нейрон имеет большое количество небольших отростков - дендритов, основной функци-
 109 ей которых является передача возбуждения к телу нейрона извне, и обычно один аксон,
 110 служащий для передачи импульса от тела другим нейронам или мышечной ткани. Полу-
 111 чается, что импульсы собираются от периферии к центру каждого нейрона, после чего
 112 суммарный импульс, если он достаточно велик, передается по аксону дальше. С помо-
 113 щью первого предположения можно объяснить распределение интенсивности в пределах
 114 группы нейронов, а с помощью второго - направленное перемещение пика интенсивно-
 115 сти. Эти утверждения можно применить не только к одному нейрону, но и к небольшой
 116 совокупности нейронов, если считать интенсивностью сигнала такой совокупности сум-
 117 марную интенсивность. В связи с этим выдвигается гипотеза, что интенсивность сигнала
 118 подчиняется модели нормального распределения: $\mathbf{I} \in N(\mathbf{m}(t), \mathbf{\Sigma}(t))$, где $\mathbf{I} \in \mathbb{R}^N$ - вектор
 119 интенсивностей, каждая компонента которого соответствует одному из N каналов. Ма-
 120 тематическое ожидание $\mathbf{m}(t)$ аппроксимирует положение пика интенсивности в момент
 121 времени t , а ковариационная матрица $\mathbf{\Sigma}(t)$ описывает форму фронта. Можно рассмотреть
 122 случай одинаково распределенных I_i , $i = 1, \dots, N$. Если предположить дополнительно,
 123 что на распределение интенсивности в пределах группы нейронов влияет направленное
 124 распространение сигнала внутри группы, можно выдвинуть гипотезу $I_i \in \Gamma(k, \Theta)$, $i =$

125 $= 1, \dots, N$, так как гамма-распределение не является симметричным. Предлагается про-
126 верить обе гипотезы экспериментально.

127 Литература

- 128 [1] David M. Alexander, Peter Jurica, Chris Trengove, Andrey R. Nikolaev, Sergei Gepshtein, Mikhail
129 Zvyagintsev, Klaus Mathiak, Andreas Schulze-Bonhage, Johanna Ruescher, Tonio Ball, and Cees
130 van Leeuwen. Traveling waves and trial averaging: The nature of single-trial and averaged brain
131 responses in large-scale cortical signals. *NeuroImage*, 73:95–112, jun 2013.
- 132 [2] Hai bin Zhao, Chun yang Yu, Chong Liu, and Hong Wang. ECoG-based brain-computer
133 interface using relative wavelet energy and probabilistic neural network. In *2010 3rd International
134 Conference on Biomedical Engineering and Informatics*. IEEE, oct 2010.
- 135 [3] David T Bundy, Mrinal Pahwa, Nicholas Szrama, and Eric C Leuthardt. Decoding three-
136 dimensional reaching movements using electrocorticographic signals in humans. *Journal of Neural
137 Engineering*, 13(2):026021, feb 2016.
- 138 [4] Cesar Marquez Chin, Milos R Popovic, Adam Thrasher, Tracy Cameron, Andres Lozano, and
139 Robert Chen. Identification of arm movements using correlation of electrocorticographic spectral
140 components and kinematic recordings. *Journal of Neural Engineering*, 4(2):146–158, apr 2007.
- 141 [5] John P. Donoghue. Bridging the brain to the world: A perspective on neural interface systems.
142 *Neuron*, 60(3):511–521, nov 2008.
- 143 [6] Andrey Elishev and Tatiana Aksenova. Stable and artifact-resistant decoding of 3d hand
144 trajectories from ECoG signals using the generalized additive model. *Journal of Neural
145 Engineering*, 11(6):066005, oct 2014.
- 146 [7] Andrey Elishev and Tetiana Aksenova. Penalized multi-way partial least squares for smooth
147 trajectory decoding from electrocorticographic (ECoG) recording. *PLOS ONE*, 11(5):e0154878,
148 may 2016.
- 149 [8] Anna Gaglianese, Ben M. Harvey, Mariska J. Vansteensel, Serge O. Dumoulin, Nick F. Ramsey,
150 and Natalia Petridou. Separate spatial and temporal frequency tuning to visual motion in human
151 measured with ECoG. *Human Brain Mapping*, 38(1):293–307, sep 2016.

-
- [9] Kejia Hu, Mohsen Jamali, Ziv B. Moses, Carlos A. Ortega, Gabriel N. Friedman, Wendong Xu, and Ziv M. Williams. Decoding unconstrained arm movements in primates using high-density electrocorticography signals for brain-machine interface use. *Scientific Reports*, 8(1), jul 2018.
- [10] Carlos A. Loza and Jose C. Principe. Unsupervised robust detection of behavioral correlates in ECoG. In *2017 8th International IEEE/EMBS Conference on Neural Engineering (NER)*. IEEE, may 2017.
- [11] Soichiro Morishita, Keita Sato, Hidenori Watanabe, Yukio Nishimura, Tadashi Isa, Ryu Kato, Tatsuhiro Nakamura, and Hiroshi Yokoi. Brain-machine interface to control a prosthetic arm with monkey ECoGs during periodic movements. *Frontiers in Neuroscience*, 8, dec 2014.
- [12] Anastasia Motrenko and Vadim Strijov. Multi-way feature selection for ECoG-based brain-computer interface. *Expert Systems with Applications*, 114:402–413, dec 2018.
- [13] I Rodriguez-Lujan, R Huerta, C Elkan, and C Santa Cruz. Quadratic programming feature selection. *Journal of Machine Learning Research*, 2010.
- [14] Roman Rosipal and Nicole Krämer. Overview and recent advances in partial least squares. In *Subspace, Latent Structure and Feature Selection*, pages 34–51. Springer Berlin Heidelberg, 2006.
- [15] J.I. Sirven. Electrocorticogram (ECOG). In *Encyclopedia of the Neurological Sciences*, pages 1080–1083. Elsevier, 2014.
- [16] Yilin Song, Yao Wang, and Jonathan Viveni. Unsupervised learning of spike patterns for seizure detection and wavefront estimation of high resolution micro electrocorticographic (μ ECoG) data. *IEEE Transactions on NanoBioscience*, 16(6):418–427, sep 2017.
- [17] Rui Zhao, Gerwin Schalk, and Qiang Ji. Coupled hidden markov model for electrocorticographic signal classification. In *2014 22nd International Conference on Pattern Recognition*. IEEE, aug 2014.