

# Прогнозирование намерений. Исследование свойств локальных моделей при пространственном декодировании сигналов головного мозга.\*

*Шиянов В. А., Болоболова Н. А., Самохина А. М., Мокруполо М. Н.*

nataboll@mail.ru

В данной работе исследуются механизмы регуляции движения конечностей нейронами головного мозга. Проверяется гипотеза о влиянии перемещения зон активности нейронов на траекторию движения конечности. Высокая размерность признакового пространства сигналов приводит к неустойчивости модели машинного обучения. Сигнал высокой размерности предлагается аппроксимировать локальной моделью, что существенно уменьшает размерность пространства параметров. Пространство параметров локальной модели используется как признаковое пространство. Таким образом, результирующая модель становится проще и устойчивее. В задаче используются данные электрокортикограмм, собранные на основе исследований активности нейронов головного мозга обезьян.

**Ключевые слова:** *Brain-Computer Interface (BCI), feature engineering.*

nataboll@mail.ru

## 1 Введение

Нейрокомпьютерный интерфейс (Brain Computer Interface) [3] позволяет восстановить мобильность людей с нарушениями двигательных функций. Алгоритм BCI транслирует сигналы нейронов головного мозга в команды для исполняющей системы [3]. Это дает возможность регулировать движение роботизированной конечности в соответствии с механизмами нервной регуляции. Исследование состоит в восстановлении зависимостей между

---

\*Работа выполнена при финансовой поддержке РФФИ, проект №00-00-00000. Научный руководитель: Стрижов В. В. Задачу поставил: Стрижов В. В. Консультант: Исаченко Р. О.

23 сигналами ECoG (electrocorticogram) и движениями конечностей. Для точного предска-  
24 зания траектории движения в трехмерном пространстве требуется снизить размерность  
25 признакового пространства. В естественной среде на сигналы моторных областей накла-  
26 дываются сторонние шумы: импульсы других долей головного мозга и сигналы из внешней  
27 среды. Огромная размерность пространства сигналов приводит к переобучению и неста-  
28 бильности алгоритма.

29  
30 Работа [1] посвящена построению модели на основе таких характеристик сигналов, как  
31 частота, амплитуда и временная локализация, но результат недостаточно устойчив по  
32 отношению к шумовым сигналам. В исследовании [6] рассмотрены механизмы простран-  
33 ственной фильтрации сигналов, снижения размерности задачи с использованием метода  
34 главных компонент и кластеризации данных методом Blind Source Separation, но полно-  
35 стью от шумовых сигналов избавиться не удалось из-за больших вариаций амплитуд. В  
36 работе [4] исследован метод отбора признаков с помощью квадратичного программирова-  
37 ния (Quadratic Programming Feature Selection [5]).

38  
39 В данной работе предлагается использовать локальную структуру сигналов. Движение  
40 фронта сигнала имеет пространственную структуру и задается небольшим количеством  
41 параметров. Как следствие, при использовании характеристик этой структуры количество  
42 параметров модели значительно уменьшается. Получается более простая аппроксимация  
43 сигнала высокой размерности, но более устойчивая модель. Параметры локальной модели  
44 используются в качестве признакового описания объекта. В смежных исследованиях [1], [2]  
45 признаки строятся только на основе частотных характеристик.

46  
47 В эксперименте используются данные с сайта <http://neurotycho.org/>. Сбор данных  
48 производился с использованием методики Multi-Dimensional Recording ([http://wiki.](http://wiki.neurotycho.org/Multi-dimensional_Recording)  
49 [neurotycho.org/Multi-dimensional\\_Recording](http://wiki.neurotycho.org/Multi-dimensional_Recording)). Запись сигналов ECoG и траектории  
50 движения руки проводилась одновременно. Каждый из экспериментов длился 15 минут,

51 первые 8 минут производилась запись обучающей выборки, оставшиеся 7 минут - запись  
52 тестовой выборки.

53

54

## 55 2 Постановка задачи

56 Данные электрокортикограммы представляют собой отрезки многомерных временных  
57 рядов  $\mathbf{X} \in \mathbb{R}^{T \times N}$ , где  $N$  – число каналов, с которых получены значения напряжения,  $T$   
58 – параметр времени. Необходимо построить признаковое пространство для предсказания  
59 траектории движения конечности  $\mathbf{y}(t) \in \mathbb{R}^{T \times 3}$ .

60 Матрицы обучающей выборки имеют вид:

$$61 \quad \mathbf{X} = \begin{pmatrix} x_{11} & \dots & x_{1N} \\ & \dots & \\ x_{T1} & \dots & x_{TN} \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} y_{11} & y_{12} & y_{13} \\ & \dots & \\ y_{T1} & y_{T2} & y_{T3} \end{pmatrix}. \quad (1)$$

62 Значение  $y_{ij}$  отвечает  $j$ -й координате траектории движения конечности, соответствующей  
63 объекту  $\mathbf{x}_i$ .

64 Итоговая модель  $f : \mathbf{X} \rightarrow \mathbf{Y}$  представима в виде композиции моделей  $g : \mathbf{X} \rightarrow \mathbf{W}$  и  $h : \mathbf{W} \times$   
65  $\Theta \rightarrow \mathbf{Y}$ , где  $\mathbf{W}$  - признаковое пространство,  $\Theta$  - параметры порождающей локальной  
66 модели  $g(\mathbf{X}, \Theta)$ . Локальная модель  $g(\mathbf{X}, \Theta)$  описывает пространственную структуру сиг-  
67 нала. Параметры  $\Theta$  являются решением задачи авторегрессии с матрицей:

$$68 \quad \left( \begin{array}{c|ccc} x_{i,t+1} & x_{i,t} & \dots & x_{i,t-n} \\ x_{i,t} & x_{i,t-1} & \dots & x_{i,t-n-1} \\ \dots & \dots & \dots & \dots \end{array} \right) \begin{pmatrix} \theta_1 \\ \theta_2 \\ \dots \end{pmatrix}. \quad (2)$$

69 Параметры  $\mathbf{w}$  регрессионной модели прогнозирования  $h(\mathbf{W}, \Theta, \mathbf{w})$  находятся путем мини-  
70 мизации функции ошибки  $L(\mathbf{X}, \mathbf{y}, \mathbf{w}, g, h)$ :

$$71 \quad \mathbf{w}^* = \arg \min_{\mathbf{w}} L(\mathbf{X}, \mathbf{y}, \mathbf{w}, g, h). \quad (3)$$

72 Цель работы состоит в нахождении оптимальной локальной модели  $g(\mathbf{X}, \Theta)$  для получения  
73 признакового пространства.

## 74 Литература

- 75 [1] Andrey Eliseyev and Tatiana Aksenova. Stable and artifact-resistant decoding of 3d hand  
76 trajectories from ECoG signals using the generalized additive model. *Journal of Neural Engineering*,  
77 11(6):066005, oct 2014.
- 78 [2] Carlos A. Loza and Jose C. Principe. Unsupervised robust detection of behavioral correlates in  
79 ECoG. In *2017 8th International IEEE/EMBS Conference on Neural Engineering (NER)*. IEEE,  
80 may 2017.
- 81 [3] Soichiro Morishita, Keita Sato, Hidenori Watanabe, Yukio Nishimura, Tadashi Isa, Ryu Kato,  
82 Tatsuhiko Nakamura, and Hiroshi Yokoi. Brain-machine interface to control a prosthetic arm with  
83 monkey ECoGs during periodic movements. *Frontiers in Neuroscience*, 8, dec 2014.
- 84 [4] Anastasia Motrenko and Vadim Strijov. Multi-way feature selection for ECoG-based brain-  
85 computer interface. *Expert Systems with Applications*, 114:402–413, dec 2018.
- 86 [5] Irene Rodriguez-Lujan, Ramon Huerta, Charles Elkan, and Carlos Santa Cruz. Quadratic  
87 programming feature selection. *Journal of Machine Learning Research*, 11(Apr):1491–1516, 2010.
- 88 [6] Yilin Song, Yao Wang, and Jonathan Viventi. Unsupervised learning of spike patterns for seizure  
89 detection and wavefront estimation of high resolution micro electrocorticographic (  $\mu$  ECoG)  
90 data. *IEEE Transactions on NanoBioscience*, 16(6):418–427, sep 2017.