

Прогнозирование намерений. Исследование свойств локальных моделей при пространственном декодировании сигналов головного мозга.*

Болобова Н. А., Мокропуло Ю. И., Самохина А. М., Шиянов В. А.,

В данной работе исследуются механизмы регуляции движения конечностей нейронами головного мозга. Проверяется гипотеза о влиянии перемещения зон активности нейронов на траекторию движения конечности. Высокая размерность признакового пространства сигналов приводит к неустойчивости модели машинного обучения. Сигнал высокой размерности предлагается аппроксимировать локальной моделью, что существенно уменьшает размерность пространства параметров. Пространство параметров локальной модели используется как признаковое пространство. Таким образом, результирующая модель становится проще и устойчивее. В задаче используются данные электрокортикограмм, собранные на основе исследований активности нейронов головного мозга обезьян.

Ключевые слова: *Brain-Computer Interface (BCI), feature engineering.*

1 Введение

Нейрокомпьютерный интерфейс (Brain Computer Interface) [1] позволяет восстановить мобильность людей с нарушениями двигательных функций. Алгоритм BCI транслирует сигналы нейронов головного мозга в команды для исполняющей системы [1]. Это дает возможность регулировать движение роботизированной конечности в соответствии с механизмами нервной регуляции. [2].

Активность нейронов представляет собой временные всплески сигналов различной интенсивности, их суперпозицию и распространение. Каждый канал имеет доступ к сигналам некоторого количества нейронов, находящихся в небольшой области пространства. Каждый нейрон соединен с помощью множества отростков с приблизительно 20 тысячами других нейронов. Именно эти сигналы представляют собой активность мозга.

В последнее время большое количество работ посвящено методам считывания мозговой активности и декодирования информации [1, 3–8]. В этой работе используются данные сигналов, полученных инвазивным методом электрокортикографии (ECoG) [9]. Сложность задачи заключается в избыточной размерности сигнала. Модель прогнозирования намерений является неустойчивой. Для построения устойчивой модели необходимо построить удобное признаковое пространство.

Исследование состоит в восстановлении зависимостей между сигналами ECoG и движениями конечностей. Для точного предсказания траектории движения в трехмерном пространстве требуется снизить размерность признакового пространства.

Стандартные подходы состоят в извлечении информативных признаков из пространственных, частотных и временных характеристик сигнала [1, 10]. Большинство методов в смежных работах исследуют частотные характеристики [5, 11, 12]. В работах [6, 13] рассматриваются все признаки вне зависимости от их природы. Наиболее распространёнными

*Работа выполнена при финансовой поддержке РФФИ, проект №00-00-00000. Научный руководитель: Стрижов В. В. Задачу поставил: Стрижов В. В. Консультант: Исаченко Р. О.




Рис. 1 Изменения значений напряжения на всех каналах

моделями являются алгоритмы PLS [6, 14], PCA [4, 15]. В работе [16] используются алгоритмы, построенные на скрытых марковских моделях. В работах [4, 5] авторы рассматривают различные участки сигнала в виде слов. В работе [13] исследован метод отбора признаков с помощью квадратичного программирования (Quadratic Programming Feature Selection [17]).

В данной работе для моделирования фронта распределения сигнала предлагается использовать локальную структуру сигнала. Нейроны и связи между ними образуют граф, описывающий возможные пути распространения сигналов. Точно учесть локальную структуру графа при описании сигнала невозможно, так как это потребует большого количества вычислительных ресурсов. В связи с этим предлагается модель локальной аппроксимации формы и перемещения фронта. На [рис.1] можно заметить, что фронт перемещается по сети в большинстве случаев как единое целое, при этом интенсивность сигнала максимальна в центре множества активных узлов и убывает к периферии. У такой структуры сигнала есть возможное объяснение, основанное на устройстве нейронной сети. Нейрон имеет большое количество небольших отростков - дендритов, основной функцией которых является передача возбуждения к телу нейрона извне, и обычно один аксон, служащий для передачи импульса от тела другим нейронам или мышечной ткани. Получается, что импульсы собираются от периферии к центру каждого нейрона, после чего суммарный импульс, если он достаточно велик, передается по аксону дальше. Таким образом, движение фронта возбуждения приближается с помощью локальной модели прогнозирования движений. В качестве признакового описания объектов используются параметры построенной локальной модели. Полученный метод значительно снижает размерность данных, использует пространственную информацию и сохраняет свойства распространения сигнала. Как следствие, количество параметров конечной модели значительно уменьшается. Получается более простая аппроксимация сигнала высокой размерности и более устойчивая прогностическая модель.

В эксперименте используются данные с сайта neurotycho.org. Сбор данных производился с использованием методики Multi-Dimensional Recording. Запись сигналов ECoG и траектории движения руки проводилась одновременно. Каждый из экспериментов длился 15

минут, первые 8 минут производилась запись обучающей выборки, оставшиеся 7 минут – запись тестовой выборки.

2 Постановка задачи

Исходные данные - отрезки многомерных временных рядов электрокортикограммы. Пространство исходных данных имеет размерность $T \times N \times F$, где N – число каналов, T – количество отсчетов времени, F – дискретный спектр наблюдаемых частот. Используем двумерное представление данных: построим матрицу значений напряжения $\mathbf{X} \in \mathbb{R}^{T \times (N \circ F)}$. Пусть $\mathbf{Y} \in \mathbb{R}^{T \times 3}$ – массив ответов. Необходимо построить информативное признаковое пространство для предсказания траектории движения конечности.

Исходные данные представлены в виде массивов:

$$\mathbf{X} = \{x_{ti}\}_{\substack{t=1,\dots,T, \\ i=1,\dots,N \circ F}}; \quad (1)$$

$$\mathbf{Y} = \{y_{ti}\}_{\substack{t=1,\dots,T, \\ i=1,2,3}}; \quad (2)$$

где \mathbf{Y} – массив ответов. Объектом будем называть вектор $\mathbf{x}_t \in \mathbb{R}^{N \circ F}$ с измерениями в каждый отрезок времени, $i = 1, \dots, T$. Вектор состоит из $N \circ F$ элементов, каждый из которых соответствует каналу и частоте. Значение y_{ti} отвечает i -й координате траектории движения конечности.

Модель прогнозирования $f : \mathbf{X} \rightarrow \mathbf{Y}$ предлагается искать классе суперпозиции двух моделей: $f = g \circ h : \mathbf{X} \rightarrow \mathbf{Y}$. Локальная модель $g : \mathbf{X} \times \Theta \rightarrow \mathbf{X}$ использует локальную пространственную структуру сигнала для аппроксимации перемещения фронта возбуждения. Примером локальной модели является модель авторегрессии:

$$\begin{pmatrix} x_{t+1,i} \\ x_{t,i} \\ \dots \\ x_{T,i} \end{pmatrix} \begin{vmatrix} x_{t,i} & \dots & x_{t-d,i} \\ x_{t-1,i} & \dots & x_{t-d-1,i} \\ \dots & \dots & \dots \\ \dots & \dots & \dots \end{vmatrix} \begin{pmatrix} \theta_1^i \\ \theta_2^i \\ \dots \\ \theta_d^i \end{pmatrix}. \quad (3)$$

Модель $g(\mathbf{X}, \Theta)$ решает задачу оптимизации параметров Θ^i для одного временного ряда \mathbf{x}_i :

$$\Theta^i(\mathbf{X}) = \arg \min_{\Theta^i} L(g(\mathbf{x}_i, \Theta^i)) \quad (4)$$

Параметры модели $g(\mathbf{X}, \Theta^i)$, $i = 1, \dots, T$, используются как новое признаковое пространство $\Theta \in \mathbb{R}^{T \times d}$. Примером модели $h(\Theta, \mathbf{w}) : \Theta \rightarrow \mathbf{Y}$ является модель линейной регрессии с параметрами \mathbf{w} . На этапе применения модели $h(\Theta, \mathbf{w})$ построенное признаковое описание Θ используется для предсказания траекторий $\hat{\mathbf{Y}}$. Параметры \mathbf{w} модели $h(\Theta, \mathbf{w})$ находятся путем минимизации функции потерь $L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h)$:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h). \quad (5)$$

В качестве функции потерь можно выбрать, например, квадратичную ошибку:

$$L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h) = \|\mathbf{Y} - \hat{\mathbf{Y}}\|_2^2. \quad (6)$$

Общая постановка задачи:

$$\mathbf{w}, \Theta = \arg \min_{\mathbf{w}, \Theta} L(\mathbf{X}, \mathbf{Y}, \mathbf{w}, g, h). \quad (7)$$

Цель работы состоит в нахождении оптимальной локальной модели $g(\mathbf{X}, \Theta)$ для построения информативного признакового пространства.

3 Выбор локальной модели

В связи с перечисленными во введении предположениями выдвигаются гипотезы:

3.1 Гипотеза нормального распределения

Интенсивность сигнала подчиняется модели нормального распределения: $\mathbf{x}_t \in \mathcal{N}(\mathbf{m}(t), \Sigma(t))$. Математическое ожидание $\mathbf{m}(t)$ аппроксимирует положение пика интенсивности в момент времени t , а ковариационная матрица $\Sigma(t)$ описывает форму фронта. Параметры распределения $\Theta = (\mathbf{m}(t), \Sigma(t))$.

3.2 Гипотеза гамма-распределения

Если предположить дополнительно, что на распределение интенсивности в пределах группы нейронов влияет направленное распространение сигнала внутри группы, можно выдвинуть гипотезу $x_{ti} \in \Gamma(k, \Theta)$, $i = 1, \dots, N$, так как гамма-распределение не является симметричным. Параметры распределения $\Theta = \{(k_i, \theta_i)\}_{i=1}^T$.

4 Базовый алгоритм

Базовым алгоритмом в данной задаче является метод частичных наименьших квадратов (далее PLS). Метод PLS относится к классу методов проекции на подпространства, которые предполагают поиск собственного базиса с последующим выбором в нем некоторого количества собственных векторов. Другие методы проекции на подпространства включают в себя метод главных компонент, линейный дискриминантный анализ и канонический корреляционный анализ.

Метод PLS выгодно отличает то, что он позволяет одновременно выявлять скрытые связи между входными данными и аппроксимировать их. Более того, существуют реализации метода PLS, позволяющие построить регрессионную модель, описывающую зависимость между входными данными. Метод PLS позволяет выделить из исходных данных компоненты, между которыми существует ковариационная связь. На основе этих компонент может быть построена модель регрессии. Такой подход позволяет не только существенно снизить вычислительные затраты, но и значительно улучшить точность модели по сравнению с линейной регрессией, построенной с помощью метода наименьших квадратов.

5 Метрики

Для оценки качества предсказания использовались метрики mean squared error, mean absolute error и r2 score:

$$mse = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$mae = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$r2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$




Рис. 2 Предсказания двухкомпонентного PLS, обученного на исходных данных

Здесь y_i — предсказываемые данные, \hat{y}_i — предсказание модели, $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ — среднее y_i .

6 Базовый эксперимент

Для проведения эксперимента, из данных электрокортикограммы были выделены частоты сигналов. Выходные данные — трехмерные координаты движения руки обезьяны. Полученные данные были разделены на обучающую и контрольную выборки в отношении два к одному. На полученной выборке был обучен PLS с различным количеством компонент (от 2 до 100). Результаты эксперимента представлены на рис. 2. На графике представлена зависимость координаты конечности от времени. Как видно из рисунка,

базовый алгоритм довольно плохо справляется с поставленной задачей. Общий профиль пиков соблюдается, однако PLS очень грубо оценивает острые пики. Также предсказание испытывает флуктуации, когда конечность почти не движется. В результате погрешность предсказания высока. Эксперимент показал значения метрик $mae = 30.17$, $mse = 1843.91$, $r^2 = 0.01$. Для борьбы с погрешностями предлагается снизить размерность входного сигнала.

7 Основной эксперимент

Для проведения основного эксперимента, для данных из базового эксперимента предлагается построить локальную модель. В качестве модели было взято нормальное распределение. Для оценки его математического ожидания предлагается считать среднее по взвешенной сумме показаний датчиков. Для оценки дисперсии (диагональных элементов матрицы ковариации) используется отклонение от среднего. Для эксперимента используются те же данные, что и в базовом эксперименте, аналогично разбитые на обучающую и контрольную выборки. Результаты эксперимента представлены на рис. 3. Как видно из рисунка, данная локальная модель плохо описывает исходные данные. Описать пики также не удалось. Избавиться от флуктуаций также не получилось. Эксперимент показал значения метрик $mae = 31.15$, $mse = 1908.62$, $r^2 = -0.03$.

Литература

- [1] Soichiro Morishita, Keita Sato, Hidenori Watanabe, Yukio Nishimura, Tadashi Isa, Ryu Kato, Tatsuhiro Nakamura, and Hiroshi Yokoi. Brain-machine interface to control a prosthetic arm with monkey ECoGs during periodic movements. *Frontiers in Neuroscience*, 8, dec 2014.
- [2] John P. Donoghue. Bridging the brain to the world: A perspective on neural interface systems. *Neuron*, 60(3):511–521, nov 2008.
- [3] Kejia Hu, Mohsen Jamali, Ziv B. Moses, Carlos A. Ortega, Gabriel N. Friedman, Wendong Xu, and Ziv M. Williams. Decoding unconstrained arm movements in primates using high-density electrocorticography signals for brain-machine interface use. *Scientific Reports*, 8(1), jul 2018.
- [4] Yilin Song, Yao Wang, and Jonathan Viventi. Unsupervised learning of spike patterns for seizure detection and wavefront estimation of high resolution micro electrocorticographic (μ ECoG) data. *IEEE Transactions on NanoBioscience*, 16(6):418–427, sep 2017.
- [5] Carlos A. Loza and Jose C. Principe. Unsupervised robust detection of behavioral correlates in ECoG. In *2017 8th International IEEE/EMBS Conference on Neural Engineering (NER)*. IEEE, may 2017.
- [6] Andrey Elishev and Tetiana Aksenova. Penalized multi-way partial least squares for smooth trajectory decoding from electrocorticographic (ECoG) recording. *PLOS ONE*, 11(5):e0154878, may 2016.
- [7] Anna Gaglianese, Ben M. Harvey, Mariska J. Vansteensel, Serge O. Dumoulin, Nick F. Ramsey, and Natalia Petridou. Separate spatial and temporal frequency tuning to visual motion in human MT measured with ECoG. *Human Brain Mapping*, 38(1):293–307, sep 2016.
- [8] David T Bundy, Mrinal Pahwa, Nicholas Szrama, and Eric C Leuthardt. Decoding three-dimensional reaching movements using electrocorticographic signals in humans. *Journal of Neural Engineering*, 13(2):026021, feb 2016.
- [9] J.I. Sirven. Electrocorticogram (ECOG). In *Encyclopedia of the Neurological Sciences*, pages 1080–1083. Elsevier, 2014.
- [10] David M. Alexander, Peter Jurica, Chris Trengove, Andrey R. Nikolaev, Sergei Gepshtein, Mikhail Zvyagintsev, Klaus Mathiak, Andreas Schulze-Bonhage, Johanna Ruescher, Tonio Ball, and Cees




Рис. 3 Предсказания двухкомпонентного PLS, обученного на параметрах локальной модели

- van Leeuwen. Traveling waves and trial averaging: The nature of single-trial and averaged brain responses in large-scale cortical signals. *NeuroImage*, 73:95–112, jun 2013.
- [11] César Márquez Chin, Milos R Popovic, Adam Thrasher, Tracy Cameron, Andres Lozano, and Robert Chen. Identification of arm movements using correlation of electrocorticographic spectral components and kinematic recordings. *Journal of Neural Engineering*, 4(2):146–158, apr 2007.
- [12] Andrey Eliseyev and Tatiana Aksenova. Stable and artifact-resistant decoding of 3d hand trajectories from ECoG signals using the generalized additive model. *Journal of Neural Engineering*, 11(6):066005, oct 2014.
- [13] Anastasia Motrenko and Vadim Strijov. Multi-way feature selection for ECoG-based brain-computer interface. *Expert Systems with Applications*, 114:402–413, dec 2018.
- [14] Roman Rosipal and Nicole Krämer. Overview and recent advances in partial least squares. In *Subspace, Latent Structure and Feature Selection*, pages 34–51. Springer Berlin Heidelberg, 2006.
- [15] Hai bin Zhao, Chun yang Yu, Chong Liu, and Hong Wang. ECoG-based brain-computer interface using relative wavelet energy and probabilistic neural network. In *2010 3rd International Conference on Biomedical Engineering and Informatics*. IEEE, oct 2010.
- [16] Rui Zhao, Gerwin Schalk, and Qiang Ji. Coupled hidden markov model for electrocorticographic signal classification. In *2014 22nd International Conference on Pattern Recognition*. IEEE, aug 2014.
- [17] I Rodriguez-Lujan, R Huerta, C Elkan, and C Santa Cruz. Quadratic programming feature selection. *Journal of Machine Learning Research*, 2010.